

Análisis de movimientos de powerlifting con redes neuronales convolucionales (CNN)

1st Ricardo Contreras Santos
Facultad de ingeniería eléctrica y electrónica
Universidad Veracruzana
Veracruz, México
Ricardo.ContrerasS@outlook.com

Abstract—La aplicación de técnicas de visión por computadora en el powerlifting permite un monitoreo preciso de la ejecución de los ejercicios, enfocándose en los tres levantamientos fundamentales: sentadilla, press de banca y peso muerto. Este enfoque ayuda a abordar riesgos de sobrecarga y progresos inconsistentes en los entrenamientos. Al analizar datos provenientes de videos, los sistemas pueden identificar patrones de movimiento, proporcionando retroalimentación y adaptando recomendaciones a las necesidades de cada atleta.

Se emplean Redes Neuronales Convolucionales (CNN) para procesar los datos visuales de los ejercicios, lo que permite una detección precisa de los movimientos. Las CNNs permiten procesar imágenes y videos de manera eficiente, asegurando alta precisión en la identificación de los patrones de movimiento. Esta automatización no solo mejora el seguimiento del rendimiento, sino que también ayuda a reducir el riesgo de lesiones y proporciona información valiosa para optimizar la ejecución de los ejercicios y las cargas escogidas, revolucionando las metodologías de entrenamiento en powerlifting.

Index Terms—Machine Learning, Powerlifting, Seguimiento de Ejercicio, Redes Neuronales Convolucionales, Redes LSTM, Análisis de Movimiento, Inteligencia Artificial, Rendimiento Deportivo, Prevención de Lesiones

I. INTRODUCCIÓN

El powerlifting, como disciplina deportiva, requiere de una técnica precisa en los tres levantamientos fundamentales: sentadilla, press de banca y peso muerto. Estos movimientos, si no se ejecutan correctamente, pueden aumentar el riesgo de lesiones y limitar el progreso de los atletas. Tradicionalmente, el monitoreo y la corrección de la técnica en estos ejercicios han dependido de la supervisión de entrenadores y la autoobservación, métodos que a menudo son subjetivos y limitados por la experiencia del atleta y la disponibilidad del entrenador.

En los últimos años, el Machine Learning ha emergido como una herramienta poderosa en la mejora del rendimiento deportivo, proporcionando una manera objetiva y precisa de analizar la ejecución de los ejercicios. A través del análisis de datos de sensores o videos, los modelos de Machine Learning pueden identificar patrones de movimiento, detectar errores técnicos y proporcionar retroalimentación en tiempo real. Esto permite a los entrenadores y atletas realizar ajustes rápidos para optimizar el rendimiento y reducir el riesgo de lesiones.

Este trabajo explora cómo los modelos de Machine Learning, como las Redes Neuronales Convolucionales (CNN) y las Redes LSTM (Long Short-Term Memory), pueden aplicarse al

seguimiento de los ejercicios básicos del powerlifting. Estos enfoques automatizados no solo mejoran la precisión en la evaluación de la técnica, sino que también personalizan las recomendaciones de entrenamiento y selección de cargas, adaptándose a las necesidades específicas de cada atleta.

A lo largo de este artículo, se discutirá el potencial de estas tecnologías para transformar el entrenamiento en powerlifting, destacando los beneficios en términos de monitoreo continuo, retroalimentación instantánea y optimización del rendimiento a largo plazo.

II. OBJETIVOS DEL PROYECTO

Los objetivos principales del proyecto son:

- 1) **Implementar Redes Neuronales Convolucionales (CNN) y modelos de Memoria a Largo Plazo (LSTM) para el reconocimiento de movimientos:** Estos modelos avanzados de aprendizaje automático se aplicarán a datos de video, con el objetivo de detectar errores en la técnica y proporcionar información útil para mejorar el rendimiento y reducir el riesgo de lesiones.
- 2) **Crear una interfaz amigable para poder probar el programa en consola:** El sistema proporcionará una interfaz en la consola de comandos donde se desplegará un menu donde podremos escoger el análisis para uno de los 3 básicos. Podremos probar el algoritmo seleccionando uno de los videos de prueba que se proporcionarán en los menús de cada uno de los ejercicios básicos del powerlifting.
- 3) **Optimizar el rendimiento:** Al proporcionar la retroalimentación de cuantas repeticiones se ejecutaron correctamente y a que velocidad se han ejecutado el usuario podrá saber si es que la carga escogida fue la correcta según las pautas de la programación de su bloque, si su velocidad no fue la esperada tendrá que reducir cargas o meter intencionalidad a la ejecución del ejercicio.
- 4) **Prevenir overshoots o undershoots:** Al proporcionar las métricas de la velocidad por cada repetición el usuario podrá evaluar si es que la carga actual es la indicada según el RPE establecido en la programación de su bloque haciendo que el usuario regule cargas o las incremente

III. ESTADO DEL ARTE

Dentro de la programación de los ejercicios de un atleta de powerlifting, se destaca la importancia de la programación por bloques, como se menciona en el estudio de [1]. Este estudio cuasiexperimental, con un diseño de preprueba-posprueba y grupo control, evaluó el efecto de un programa de entrenamiento basado en la periodización en bloques durante 14 semanas. Los resultados mostraron un aumento significativo en los niveles de fuerza máxima (10 kg en 1RM) y fuerza explosiva (27,84 cm) en el grupo experimental, mientras que el grupo control no presentó cambios significativos. Los datos sugieren que este enfoque de entrenamiento es eficaz para mejorar la fuerza en deportistas de Para powerlifting, con una significancia estadística de $p < 0.05$.

La evolución de la exigencia en los deportes de élite ha impulsado la integración de nuevas ciencias aplicadas al rendimiento deportivo, como el análisis de datos. Este enfoque busca mejorar el rendimiento individual y colectivo, prevenir lesiones y proporcionar un panorama táctico más amplio. Según [2], uno de los avances más recientes es la implementación del Internet de las Cosas (IoT) en el análisis del rendimiento deportivo. Este sistema captura información a través de sensores, pero requiere un análisis matemático para obtener datos más precisos y fiables. El estudio describe cómo se realiza el análisis y las problemáticas enfrentadas en la medición de la aceleración, velocidad y distancia en tiempo real, utilizando una arquitectura de software comúnmente empleada en el ámbito de IoT.

En el contexto de las pruebas de una repetición máxima (1RM), los levantadores buscan alcanzar un límite en su levantamiento sin caer en la fatiga prematura ni intentar levantar una carga más allá de su capacidad actual. En powerlifting, específicamente en los ejercicios de sentadilla, press de banca y peso muerto, los atletas tienen un máximo de tres intentos por levantamiento y deben estructurar cuidadosamente sus intentos para lograr el objetivo. En este sentido, el uso de herramientas que midan la dificultad y ayuden en la selección de los intentos son beneficiosas para los atletas. Según [3], el uso de la Escala de Esfuerzo Percibido (RPE, por sus siglas en inglés) ha sido una práctica común durante casi 50 años para medir el esfuerzo. En su investigación, desarrollaron una escala específica para entrenamiento de resistencia que mide las repeticiones en reserva (RIR), donde los sujetos proporcionan un valor de RPE después de intentar un 1RM en sentadilla. Además, evaluaron la velocidad concéntrica promedio (ACV) durante cada intento de 1RM y usaron esta información en conjunto con el RPE para determinar el siguiente intento. Los resultados mostraron que la combinación de estas variables proporciona una retroalimentación más precisa que cuando se utilizan de manera aislada. De hecho, cuando el levantamiento se realiza a la velocidad máxima deseada, una disminución en la velocidad concéntrica puede determinar objetivamente una mayor intensidad de esfuerzo [3]. Sin embargo, aunque estos avances en la escala RPE/RIR y su uso junto con la velocidad han demostrado ser útiles en el levantamiento de

sentadilla, quedan dudas sobre su validez para determinar el 1RM en el press de banca y el peso muerto. Por lo tanto, el estudio de [3] se propuso evaluar tanto el RPE basado en RIR como la velocidad promedio en powerlifters competitivos, en los tres levantamientos, con el fin de determinar cualquier relación entre RPE y velocidad promedio.

El análisis de los movimientos deportivos es esencial para optimizar el rendimiento y prevenir lesiones. En el powerlifting, movimientos como el press de banca, el peso muerto y la sentadilla requieren una técnica adecuada para evitar riesgos. Un estudio reciente [4] utilizó métodos de aprendizaje profundo para clasificar estos movimientos y asegurar su correcta ejecución. Usaron el modelo SqueezeNet para extraer características, seguido de una clasificación con algoritmos de machine learning. Los resultados mostraron que el modelo de Red Neuronal alcanzó la mayor precisión (0.989), mejorando con técnicas de aumento de datos y estimación de postura. Este estudio demuestra la efectividad de los métodos de aprendizaje profundo en el análisis de movimientos deportivos.

En los últimos años, el ejercicio ha ganado popularidad rápidamente. El entrenamiento con pesas para moldear el cuerpo es una tendencia particular, pero posturas incorrectas pueden anular los beneficios del ejercicio e incluso causar daños permanentes. Por ello, muchos entrenadores recurren a un entrenador personal, aunque su costo puede ser elevado a largo plazo. En este estudio, [5] utiliza el sistema OpenPose y cámaras web económicas para desarrollar el algoritmo WTPose, que determina en tiempo real si la postura de un usuario en el entrenamiento con pesas es correcta. Si se detecta alguna desviación, el algoritmo muestra la postura correcta, permitiendo al usuario corregirla a bajo costo. Los experimentos demostraron que el algoritmo WTPose puede identificar con precisión la postura correcta, independientemente de la forma corporal o el género del usuario.

Tradicionalmente, el entrenamiento de fuerza ha utilizado el 1RM y el nRM como indicadores para dosificar las variables de carga. Sin embargo, esto presenta inconvenientes como la variabilidad diaria del RM y la necesidad de realizar pruebas frecuentes para ajustar las cargas de entrenamiento. [6] destaca que la velocidad de ejecución ha demostrado ser un parámetro confiable para controlar estas variables, mostrando correlaciones casi perfectas para predecir el RM diario y el porcentaje del RM correspondiente a una carga. Esta herramienta, al emplear la velocidad media como variable principal, resulta útil para asegurar que el atleta realice series y repeticiones con el porcentaje de RM exacto planificado. Además, [6] señala que pérdidas de un 20 por ciento interserie favorecen la recuperación completa del atleta, lo que permite entrenar con mayor frecuencia y obtener mayor especialización en el gesto deportivo, lo que podría traducirse en un mayor potencial de mejora.

Los deportes que requieren altos niveles de fuerza y potencia suelen emplear métodos tradicionales basados en porcentajes (1RM). Sin embargo, estos métodos no consideran el estado biológico diario del atleta. Por ello, se ha propuesto el entrenamiento basado en la velocidad (VBT) como una

alternativa para mejorar el rendimiento. [7] investigó la fiabilidad del acelerómetro PUSH para medir la velocidad máxima durante ejercicios como el salto con barra (SJ) y comparó los efectos del entrenamiento VBT con el tradicional (1RM) en fuerza (sentadilla [BS], press de banca [BP]) y potencia. Los resultados mostraron alta fiabilidad en la medición de velocidad con el PUSH (ICC 0.91 y 0.90) y no se encontraron diferencias significativas en fuerza y potencia entre los grupos ($p < 0.05$). Se sugiere continuar con investigaciones en otros ejercicios tradicionales y con muestras más grandes para obtener resultados más claros.

En resumen, el entrenamiento de powerlifting tradicionalmente utiliza el 1RM para dosificar las cargas, pero este método no tiene en cuenta el estado biológico diario del atleta. Recientemente, se ha propuesto el entrenamiento basado en la velocidad (VBT) como una alternativa más precisa para mejorar el rendimiento, respaldado por investigaciones que demuestran la fiabilidad de dispositivos como el acelerómetro PUSH para medir la velocidad en ejercicios clave como la sentadilla, press de banca y peso muerto.

Mi proyecto busca implementar redes neuronales convolucionales (CNN) para cuantificar en tiempo real la velocidad y las repeticiones de estos levantamientos, optimizando así el entrenamiento y permitiendo a los atletas mejorar su rendimiento de manera precisa, sin necesidad de intervención constante de un entrenador.

IV. DISEÑO E IMPLEMENTACIÓN

Diseño del Sistema:

El sistema se basa en un modelo preentrenado de visión por computadora, que será integrado a través de una API para analizar los desplazamientos de la barra en los ejercicios de powerlifting. El flujo de trabajo del sistema es el siguiente:

1. Captura de video: El usuario deberá capturar un video del ejercicio realizado, asegurándose de que el entorno tenga buena iluminación y que la toma sea estable y paralela al movimiento. Este video es procesado para extraer la información de los movimientos de la barra.

2. Predicción de la ubicación de la barra**: El modelo preentrenado, que se encuentra disponible en [Roboflow](https://universe.roboflow.com/gi-inn/barbelld/model/3), se integrará a través de su API para hacer predicciones en tiempo real sobre la ubicación de la barra en los ejes X y Y del video. El modelo identificará los desplazamientos de la barra y los guardará en un archivo .txt.

3. Procesamiento de los desplazamientos: Una vez obtenidas las predicciones del modelo, el algoritmo tomará solo los desplazamientos a lo largo del eje Y, que indican el movimiento vertical de la barra. Estos datos serán analizados para detectar los distintos estados del ejercicio.

4. Análisis de estados: En base a los desplazamientos en el eje Y, el algoritmo analizará cuándo comienza y termina cada repetición. Por ejemplo, en la **sentadilla**, el análisis empezará cuando detecte un movimiento en el eje Y, asumiendo que la repetición comienza cuando la barra baja.

Este análisis se realiza mediante la detección de patrones en los desplazamientos y la comparación con las características esperadas del ejercicio.

5. Retroalimentación al usuario: Finalmente, el sistema proporcionará retroalimentación al usuario sobre la correcta ejecución del movimiento, indicando si la repetición fue ejecutada correctamente o si hubo algún error en la técnica. Además, se podrá determinar la velocidad de ejecución de cada repetición, lo que permitirá ajustar la dosificación del entrenamiento.

Implementación:

1. Recopilación de datos: Inicialmente, se recopilarán videos de los ejercicios de powerlifting en un entorno controlado, asegurando la estabilidad y buena iluminación en las tomas. Estos videos servirán para realizar pruebas y evaluar el rendimiento del modelo.

2. Integración con la API de Roboflow: Se integrará el modelo preentrenado mediante la API de Roboflow para obtener las predicciones de la ubicación de la barra en los ejes X y Y en tiempo real. Estas predicciones se almacenarán en un archivo .txt, que luego será procesado por el algoritmo.

3. Procesamiento de desplazamientos: El sistema analizará los desplazamientos en el eje Y de los datos obtenidos para detectar patrones de movimiento y determinar en qué parte de la repetición se encuentra el atleta (por ejemplo, cuando está bajando, levantando o terminando la repetición).

4. Evaluación del rendimiento: Se evaluará la precisión del sistema al identificar las repeticiones y la velocidad de ejecución. Esto se comparará con métodos tradicionales, como el cálculo de repeticiones manual o basado en el 1RM, para determinar la efectividad y utilidad del sistema.

5. Pruebas en condiciones reales: Finalmente, se probará el sistema en un entorno de entrenamiento real con atletas, para ver cómo se adapta a distintos estilos de levantamiento y cómo puede ayudar en la optimización del entrenamiento de powerlifting.

Justificación:

El uso de visión por computadora y modelos de aprendizaje automático para el análisis de movimientos en tiempo real es una solución avanzada que permite optimizar la dosificación del entrenamiento. Al basar el sistema en el análisis de desplazamientos verticales de la barra, se evita la necesidad de intervención constante de un entrenador y se proporciona un monitoreo preciso del rendimiento del atleta. Esto representa una mejora significativa frente a los métodos tradicionales de entrenamiento, como el uso del 1RM, al ofrecer una retroalimentación continua y basada en datos objetivos.

Este enfoque permite que los atletas optimicen su entrenamiento de powerlifting mediante la cuantificación precisa de sus movimientos, mejorando tanto la técnica como el rendimiento sin la necesidad de intervención constante de un entrenador.

V. RESULTADOS

En esta sección se presentan los resultados obtenidos a partir de las pruebas realizadas en la implementación del

sistema de gestión de asesorías deportivas online. Las pruebas incluyeron la evaluación del desempeño, la funcionalidad, y la comparativa con una implementación anterior para medir mejoras en el sistema.

Desempeño del Sistema:

Se realizaron pruebas de rendimiento en una PC ASUS VivoBook 512J con su configuración de fábrica, utilizando el sistema operativo Windows 10. Las pruebas se basaron en el modelo BarbellID de Roboflow (<https://universe.roboflow.com/gi-inn/barbellid/model/3>), el cual se configuró con los mismos niveles de confianza para procesar videos de ejercicios específicos.

El modelo logró una tasa de éxito del 100 porciento en la detección de ejercicios para todos los videos utilizados en las pruebas, cuando las configuraciones de confianza fueron adecuadamente ajustadas. A continuación se detallan las configuraciones de confianza que fueron efectivas para cada video:

SentadillaP1: Confianza del 40DeadliftP3: Confianza del 40DeadliftP1: Confianza del 40DeadliftP3: Confianza del 40BP2: Confianza del 40BP1: Confianza del 40SentadillaP6: Confianza del 40

En cuanto al rendimiento general del sistema en la PC utilizada, se evaluó el tiempo de procesamiento de los videos bajo las mismas configuraciones de confianza sin embargo hay una discrepancia en los datos con respecto a la duración del video, dado que si los videos son más largos tenderán a tardar más dado los fps del video. Todos los videos vienen configurados en 60fps:

Tiempo promedio de procesamiento para videos con confianza del 40 porciento y duración de (SentadillaP1): 4 minutos con 53 segundos.

Funcionalidad del Sistema: El sistema desarrollado utiliza el modelo BarbellID de Roboflow para la detección automática de ejercicios a partir de videos. El sistema está diseñado para procesar videos de ejercicios específicos y proporcionar resultados precisos en tiempo real, con un enfoque particular en la detección de barras y la identificación de movimientos específicos de levantamiento de pesas.

El sistema opera de la siguiente manera: Procesamiento de videos: El sistema toma como entrada videos grabados en 60 fps, los cuales son procesados por el modelo de aprendizaje automático entrenado para identificar distintos ejercicios de levantamiento de pesas, tales como sentadillas, deadlifts y bench press. El modelo BarbellID se configura para trabajar con diferentes niveles de confianza para cada tipo de video.

Configuración de confianza: Para cada video de ejercicio, el modelo tiene un umbral de confianza ajustable que determina la precisión de las predicciones. Durante las pruebas, se determinó que un 40 porciento de confianza era suficiente para obtener una tasa de éxito del 100 porciento en la detección de ejercicios para los videos utilizados. Sin embargo, en ciertos videos, la configuración de confianza varió según el tipo de ejercicio, como se describe a continuación: SentadillaP1: Confianza del 40DeadliftP3: Confianza del 40DeadliftP1: Confianza del 40DeadliftP3: Confianza del 40BP2: Confianza del 40BP1: Confianza del 40SentadillaP6: Confianza del 40

Tiempo de procesamiento: El sistema evalúa el tiempo que tarda en procesar los videos, siendo este tiempo influenciado por la duración del video y la tasa de fotogramas por segundo (fps). Los resultados de procesamiento son proporcionales a la duración de los videos. En las pruebas realizadas, el tiempo promedio de procesamiento para el video SentadillaP1 fue de 4 minutos con 53 segundos con una configuración de confianza del 40

Comparación con el modelo anterior: El sistema de detección actual, basado en el modelo BarbellID de Roboflow, demostró una notable mejora respecto al modelo anterior, que utilizaba YOLOv11. En las pruebas previas, YOLOv11 no fue capaz de lograr una tasa de éxito adecuada, obteniendo solo un 25 porciento de confianza para la detección de barras y con frecuencia perdiendo predicciones clave. Esta deficiencia en la precisión del modelo YOLOv11 hizo que no fuera adecuado para la tarea, mientras que el modelo BarbellID alcanzó una tasa de éxito del 100 porciento en las pruebas realizadas.

En resumen, el sistema desarrollado presenta una solución robusta para la detección de ejercicios en videos, con una tasa de éxito sobresaliente en la identificación precisa de movimientos de levantamiento de pesas y una mejora significativa en comparación con modelos anteriores.

Observaciones:

Durante las pruebas, se detectaron algunos comportamientos inesperados en la carga de videos en condiciones de alta carga, lo que resultó en una pequeña disminución en la tasa de éxito. Estos errores fueron causados por el procesamiento insuficiente en el servidor, lo que podría mejorarse mediante optimización en la infraestructura de backend.

Limitaciones:

Las pruebas se realizaron en un entorno controlado con una cantidad limitada de usuarios y con un solo tipo de dispositivo (PC de escritorio). Los resultados pueden variar en condiciones de producción con una mayor diversidad de dispositivos y usuarios. Además, no se realizaron pruebas a largo plazo para evaluar la estabilidad del sistema a lo largo del tiempo.

VI. CONCLUSIONES Y TRABAJO FUTURO

Conclusiones:

El sistema desarrollado ha demostrado ser altamente efectivo en la detección de ejercicios en videos de levantamiento de pesas, alcanzando una tasa de éxito del 100 porciento en las pruebas realizadas con el modelo BarbellID de Roboflow. El sistema es capaz de identificar con precisión movimientos clave, como sentadillas, deadlifts y bench press, utilizando configuraciones de confianza personalizadas para cada tipo de ejercicio. A través de las pruebas realizadas en una PC ASUS VivoBook 512J con Windows 10, se ha comprobado que el sistema es capaz de procesar videos con una tasa de procesamiento promedio eficiente, logrando tiempos razonables de ejecución, especialmente para videos de ejercicios con configuraciones de confianza del 40

La comparación con el modelo anterior basado en YOLOv11 resalta una mejora significativa en el rendimiento.

Mientras que el modelo YOLOv11 no fue capaz de proporcionar resultados consistentes debido a su baja tasa de confianza (25 por ciento) y su tendencia a perder predicciones, el modelo BarbellD logró una mejora considerable tanto en precisión como en confiabilidad, demostrando ser una solución más adecuada para la detección de ejercicios en videos.

En general, el sistema presenta un alto nivel de funcionalidad y efectividad, destacándose por su capacidad para adaptarse a diferentes configuraciones de confianza, lo cual lo convierte en una herramienta valiosa para entrenadores y usuarios interesados en el análisis y seguimiento de ejercicios.

Trabajo futuro: Aunque el sistema ha demostrado ser eficiente y efectivo, existen áreas para mejorar y expandir su funcionalidad en futuras versiones. A continuación, se presentan algunas áreas clave para el trabajo futuro:

Optimización del rendimiento: Si bien el sistema ha demostrado un rendimiento satisfactorio, el tiempo de procesamiento puede mejorarse mediante la optimización del modelo y la implementación de técnicas de procesamiento en paralelo o en la nube, lo que permitiría reducir los tiempos de espera y hacer el sistema más eficiente en entornos de trabajo con recursos limitados.

Ampliación de la base de datos de entrenamiento: El modelo actual se entrena con una base de datos limitada de videos de ejercicios. Para mejorar la precisión y la capacidad del sistema para manejar una gama más amplia de movimientos, sería beneficioso ampliar la base de datos con más videos de diferentes ejercicios, variaciones de movimientos, y tipos de cuerpo.

Mejora en la precisión de detección en condiciones desafiantes: Aunque el sistema tiene un buen rendimiento en condiciones ideales, hay áreas en las que podría mejorar, como la detección de ejercicios en condiciones de baja iluminación, ángulos poco comunes o cuando los movimientos son parcialmente bloqueados por el equipo. Investigar el uso de modelos de visión computacional más avanzados, como redes neuronales convolucionales (CNNs) más profundas, podría ayudar a abordar estos desafíos.

Integración con plataformas de entrenamiento en línea: Una mejora importante sería la integración del sistema con plataformas de entrenamiento en línea o aplicaciones móviles para que los usuarios puedan cargar sus videos directamente a través de estas plataformas y recibir análisis automáticos de sus ejercicios en tiempo real.

Entrenamiento en tiempo real y feedback: Para hacer que el sistema sea aún más útil para los entrenadores y los usuarios, se podría investigar la posibilidad de implementar un sistema de retroalimentación en tiempo real, donde los usuarios reciban comentarios sobre la ejecución de sus ejercicios mientras los están realizando. Esto podría hacerse mediante el uso de cámaras en tiempo real y un modelo optimizado para el procesamiento rápido de datos.

Análisis en tres ejes para el movimiento de la barra: Un avance significativo para el sistema sería incorporar el análisis en tres ejes (X, Y, Z) para poder determinar de manera más precisa cómo se mueve la barra en el espacio. Esto permitiría

un cálculo más detallado de la velocidad y el conteo de repeticiones, mejorando la precisión en la evaluación de los ejercicios. Al tomar en cuenta estos tres ejes, también se podría empezar a evaluar la ejecución de los movimientos, como la alineación de la barra y la trayectoria del levantamiento, lo cual es crucial para asegurar la correcta ejecución de los ejercicios y prevenir lesiones.

Adaptación del sistema a otros tipos de ejercicios: Ampliar el sistema para que pueda reconocer no solo ejercicios de levantamiento de pesas, sino también otras actividades físicas como carreras, yoga o entrenamiento funcional, abriendo nuevas oportunidades para su aplicación en diversas disciplinas deportivas.

Estas áreas representan solo algunas de las direcciones que podrían ser exploradas en el trabajo futuro para continuar mejorando el sistema y ampliando sus capacidades, haciendo que sea aún más preciso, rápido y adaptable a las necesidades de los usuarios.

REFERENCES

- [1] C. A. A. Ruiz Marulanda, Victor Alfonso, "Efecto del modelo de periodización en bloques en el incremento de la fuerza máxima y fuerza explosiva de practicantes de para powerlifting de tuluá 2020," *Trabajo de grado*, 2020.
- [2] G. F. Carrilao Ávila, "Uso de gps y acelerómetro para medir performance en deporte de élite," *Investigación*, 2018.
- [3] A. C. M. R. B. S. R. L. S. R. H. D. C. Z. M. C. Helms, Eric R. Storey, "Rpe and velocity relationships for the back squat, bench press, and deadlift in powerlifters," *Investigación*, 2017.
- [4] "Deep learning-based classification of powerlifting movements using mediapipe," *Investigación*, 2024.
- [5] C.-Y. L. . K.-C. Jian, "A real-time algorithm for weight training detection and correction," *Artículo*, 2022.
- [6] G. Fernández Zamorano, "Entrenamiento de la fuerza basado en la velocidad de ejecución," *Trabajo de grado*, 2018.
- [7] H. T. U. O. R. Peta, "The influence of velocity-based resistance training on strength and power development," *Investigación*, 2019.